Projet de Regréssion Linéaire

Liao Yonghan 3GM

Table de matière

Table de matière
1 Présentation du problème
1.1 Introduction
Données:
1.2 Description des variables
1.2 Identification des corrélations
1.3 Prétraitement des données
2 Un premier modèle
3 Un deuxième modèle
3.1 Suppression des paramètres non-significatifs
3.2 Tests d'hypothèses
3.3 Analyse des résidus&Etude des points influents
4 Modèle Final
4.1 Validation du modèle
4.2 Intervalles de confiance
4.3 Prediction
5 Complément
6 Interprétation des résultats
Annexe

1 Présentation du problème

1.1 Introduction

Le projet proposé porte sur l'étude de l'évolution de la flotte d'avions courts et moyens courriers.

Notre objectif est d'utiliser le modèle de régression linéaire appris pour effectuer une analyse de régression basée sur l'ensemble de données donné, et enfin trouver la relation entre la variable explicative et d'autres variables. Afin d'établir un modèle de régression linéaire fiable et suffisamment ajusté, qui peut aider les compagnies aériennes à faire des prévisions plus précises et à prendre de meilleures décisions.

Il convient de souligner que dans ce rapport, notre modèle de régression linéaire est basé sur la méthode des moindres carrés (bien sûr, il existe d'autres méthodes d'ajustement, qui ne seront pas développées ici).

Données:

	Flotte_Avion	CPI	Conso_gouv	Conso_privee	Exports	GDP	Imports	Investissements
1980	4117	4.55	5397050	15342760	3035489	26097570	2938414	5636050
1981	4146	5.29	5521020	15509850	3149749	26552290	2959279	5642570
1982	4079	6.10	5648560	15783030	3148182	26657620	2919592	5511250
1983	4173	6.98	5782760	16260580	3237183	27404190	2977685	5605220
1984	4221	8.00	5888010	16768230	3525617	28681340	3298031	5963300

Le tableau de donées

1.2 Description des variables

Voici une liste exhaustive des variables de données :

- **Annee** (donnée uniquement à titre indicatif)
- **Flotte_Avion** : Nombre d'avions constituant la flotte mondiale courts et moyens courriers (variable à expliquer)
- **Investissement** : Total des Investissements fixes mondiaux
- **GDP** : PIB mondial
- **Imports** : Total des Importations mondiales ;
- **Exports** : Total des Exportations mondiales;
- **CPI** : Consumer Price Index mondial ;
- **Conso_gouv** : Consommation publique mondiale ;
- **Conso_privee** : Consommation privée mondiale.

```
> summary(data)
  Flotte_Avion        CPI            Conso_gouv
 Min.   : 4079   Min.   :  4.55   Min.   : 5397050
 1st Qu.: 5440   1st Qu.: 18.14   1st Qu.: 6894030
 Median : 7853   Median : 65.78   Median : 8438105
 Mean   : 8380   Mean   : 62.55   Mean   : 9073351
 3rd Qu.:10574   3rd Qu.: 97.33   3rd Qu.:11601460
 Max.   :15848   Max.   :134.50   Max.   :14160420
  Conso_privee         Exports              GDP
 Min.   :15342760   Min.   : 3035489   Min.   :26097570
 1st Qu.:20589088   1st Qu.: 4838702   1st Qu.:35203525
 Median :27525250   Median : 9139250   Median :46956900
 Mean   :28775653   Mean   :10547012   Mean   :49634596
 3rd Qu.:36172118   3rd Qu.:15871485   3rd Qu.:62943775
 Max.   :47646500   Max.   :22599130   Max.   :83856800
    Imports          Investissements
 Min.   : 2919592   Min.   : 5511250
 1st Qu.: 4844630   1st Qu.: 7921668
 Median : 9340700   Median :10980225
 Mean   :10378484   Mean   :11873670
 3rd Qu.:15466418   3rd Qu.:15260530
 Max.   :22005880   Max.   :22485540
```

Le summary de variables

A partir des données originales, nous pouvons approximativement obtenir les informations suivantes. Nous pouvons voir que le trafic aérien mondial a augmenté régulièrement d'année en année, et les autres indices correspondants tels que l'**CPI/IPC**, le **GDP/PIB**, l'**Imports** et l'**Exports**, l'**Investissement**, etc. montrant une tendance à la hausse d'année en année. On peut donc naturellement tirer une conclusion préliminaire que la flotte d'avions est positivement corrélé avec le niveau économique mondial. C'est très intuitif, car le fondement économique détermine la superstructure. Lorsque le niveau économique s'améliore, les gens seront plus enclins à utiliser le mode de transport le plus cher qu'est l'avion.

Autrement, à partir de wikipedia :

Gross domestic product - Wikipedia

Gross domestic product (GDP) is a monetary measure of the market value of all the final goods and services

𝕎 https://en.wikipedia.org/wiki/Gross_domestic_product

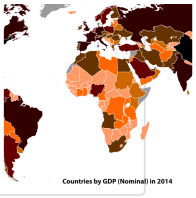

GDP (Y) is the sum of **consumption (C)**, **investment (I)**, **government spending (G)** and **net exports (X – M)**.

$$Y = C + I + G + (X - M)$$

Donc, nous avons remarqué que ces variables existent déjà dans l'ensemble de données, de sorte que les variables explicatives seront certainement linéairement liées au **GDP/PIB**. Afin d'éviter des ajustements répétés, nous n'avons pas l'intention d'inclure le **GDP/PIB** dans la plage d'analyse du modèle de régression linéaire.

1.2 Identification des corrélations

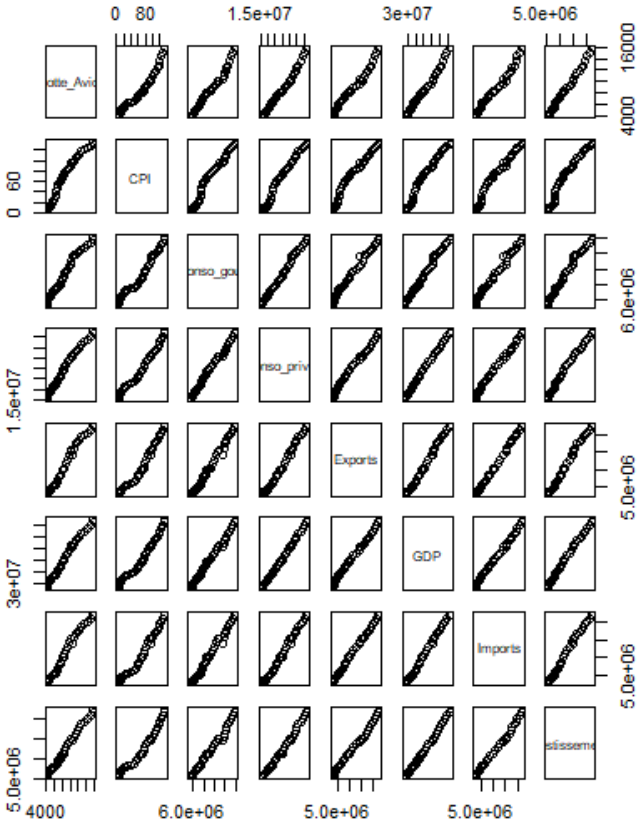

Graphique Corrélations

À l'aide de la fonction de `pairs`, nous présentons la relation entre toutes les variables par paires dans un graphique. À partir de la figure, nous pouvons intuitivement conclure que toutes les variables semblent avoir une corrélation positive linéaire très claire entre elles. En d'autres termes, si l'une des variables connexes telles que l'**CPI** et le **Exports** augmente, la variable explicative **Flotte_Avion** augmentera également avec une forte probabilité. Cependant, ce à

quoi nous devons faire attention, c'est que la relation linéaire entre chaque variable est trop cohérente, et nous avons commencé à réfléchir à l'existence d'une variable en surpoids qui affecte notre jugement. Il est très probable qu'il s'agisse du **GDP/PIB**. Combiné avec la compréhension antérieure de la source des données du **PIB**, nous avons suffisamment de preuves pour prouver qu'il ne devrait pas être pris en considération.

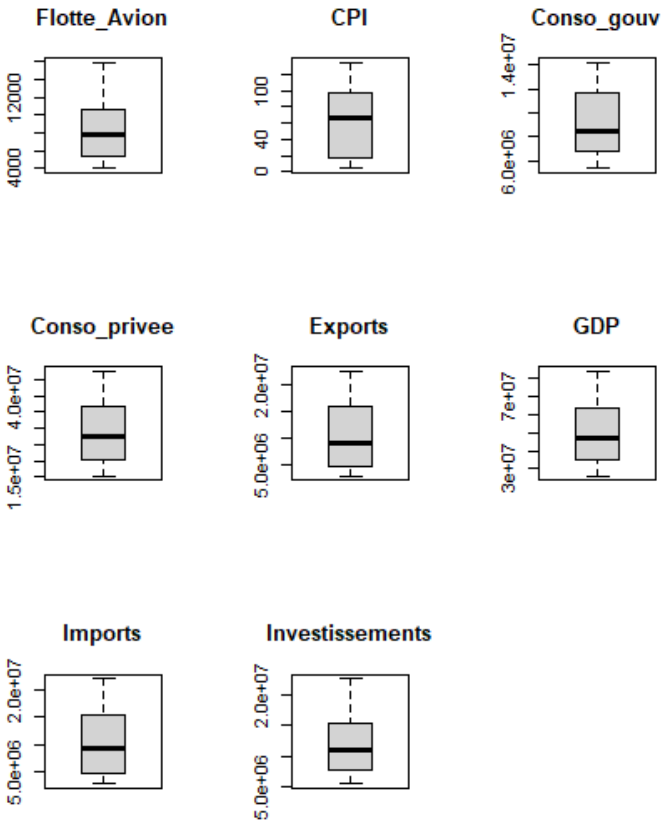

Boxplot pour les différentes variables

À l'aide de la fonction `boxplot`, nous pouvons voir approximativement si les données ont une symétrie, le degré de dispersion et d'autres informations, nous n'avons trouvé aucun individu anormal dans la Boxplot.

1.3 Prétraitement des données

Avant d'effectuer une analyse de régression formelle, nous devons effectuer un prétraitement sur les données d'origine pour garantir de meilleurs résultats d'analyse.

- La lecture des données montre que les unités des données sont très grandes, des dizaines de milliers à chaque tour.Nous pouvons utiliser la fonction log() pour réduire l'échelle afin d'assurer la précision du calcul.
- Comme mentionné précédemment, nous n'incluons pas le PIB dans le champ statistique, car il a montré une forte corrélation avec les variables explicatives et interférera avec d'autres variables connexes. Alors on le supprime

2 Un premier modèle

Étant donné que les conditions de régression linéaire (linéarité, normalité, homogénéité de la variance et indépendance) sont complétées par des résidus, l'équation de régression peut être établie en premier, puis les conditions de régression linéaire peuvent être testées grâce au diagnostic de régression. On va donc réaliser un premier modèle à l'aide de commande `lm()`

```
Call:
lm(formula = Flotte_Avion ~ ., data = data)

Residuals:
      Min        1Q    Median        3Q       Max 
-0.048424 -0.020545  0.001743  0.018188  0.063049 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)     -9.24647    2.51681  -3.674 0.000840 ***
CPI              0.06600    0.02286   2.887 0.006815 ** 
Conso_gouv      -0.26371    0.34319  -0.768 0.447706    
Conso_privee     0.74115    0.63129   1.174 0.248787    
Exports          0.61373    0.24593   2.496 0.017751 *  
Imports         -0.92614    0.27324  -3.390 0.001829 ** 
Investissements  0.89188    0.24601   3.625 0.000961 ***
---
Signif. codes:  
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.02742 on 33 degrees of freedom
Multiple R-squared:  0.9964,	Adjusted R-squared:  0.9958 
F-statistic:  1530 on 6 and 33 DF,  p-value: < 2.2e-16
```

Dans le résultat, *Coefficients* est le résultat de l'estimation des paramètres. Les résultats ont montré que le terme d'interception et le système de régression étaient statistiquement significatifs. L'évaluation du modèle simple R^2 est de 0,9964, et le coefficient de correction de détermination R^2_{adj} est de 0,9958. Plus le coefficient de détermination est élevé, plus le degré d'explication de la variable indépendante par rapport à la variable dépendante est élevé. Le test F teste si toutes les variables prédictives prédisent que les variables de réponse sont au-dessus d'un certain niveau de probabilité, le résultat montre $(F = 1530, P < 2.2e - 16)$, l'équation globale est statistiquement significative. L'erreur standard du résidu peut être considérée comme l'erreur moyenne de la variable dépendante prédite par la variable indépendante. L'équation établie est:

$$Flotte_Avion = -9.24647 + 0.066CPI - 0.26371Conso_gouv + 0.74115Conso_privee + 0.61373Exports - 0.92614Imports + 0.89188Investissements$$

Remarque: *tous les termes sont en log()*

3 Un deuxième modèle

Nous pouvons effectivement dire que nous avons construit un bon modèle, mais nous avons remarqué que certaines variables ne montraient pas de corrélation trop forte. Afin de rendre notre modèle de régression plus précis, nous commençons le diagnostic de régression, nous devons d'abord effectuer une sélection de variables. L'objectif est de réduire le nombre de prédicteurs candidats tout en ne perdant pas trop de pouvoir explicatif. Pour ce processus,

nous pouvons juger et choisir manuellement en fonction de la signification des coefficients de régression de chaque variable prédictive dans la régression.

3.1 Suppression des paramètres non-significatifs

La règle est le suivante:

> " La stratégie à appliquer pour supprimer les bonnes variables est de supprimer la variable qui a la **p_value la plus élevée** et d'effectuer un nouveau modèle avec les variables restantes. Ensuite il faut recommencer la manœuvre plusieurs fois (en supprimant les variables une par une) jusqu'à obtenir un modèle avec uniquement des variables significatives au seuil de 5%."

```
> reg1 <- lm(Flotte_Avion~.,data=data)
> summary(reg1)

Call:
lm(formula = Flotte_Avion ~ ., data = data)

Residuals:
      Min        1Q    Median        3Q       Max 
-0.048424 -0.020545  0.001743  0.018188  0.063049 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)     -9.24647    2.51681  -3.674 0.000840 ***
CPI              0.06600    0.02286   2.887 0.006815 ** 
Conso_gouv      -0.26371    0.34319  -0.768 0.447706    
Conso_privee     0.74115    0.63129   1.174 0.248787    
Exports          0.61373    0.24593   2.496 0.017751 *  
Imports         -0.92614    0.27324  -3.390 0.001829 ** 
Investissements  0.89188    0.24601   3.625 0.000961 ***
---
Signif. codes:  
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.02742 on 33 degrees of freedom
Multiple R-squared:  0.9964,	Adjusted R-squared:  0.9958 
F-statistic:  1530 on 6 and 33 DF,  p-value: < 2.2e-16
```

On va donc supprimer dans un premier temps **Conso-gouv** parce qu'il possède une p-value de 0,4477

Ensuite, on va supprimer **Conso_privee** qui possède une p-value de 0.3429

```
> reg2 <- lm(Flotte_Avion~.-Conso_gouv,data = data)
> summary(reg2)

Call:
lm(formula = Flotte_Avion ~ . - Conso_gouv, data = data)

Residuals:
      Min        1Q    Median        3Q       Max 
-0.048876 -0.021032  0.000742  0.019585  0.061118 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)     -8.41582    2.25911  -3.725 0.000706 ***
CPI              0.07245    0.02113   3.429 0.001607 ** 
Conso_privee     0.34079    0.35431   0.962 0.342911    
Exports          0.50050    0.19570   2.557 0.015175 *  
Imports         -0.78301    0.19870  -3.941 0.000384 ***
Investissements  0.97270    0.22105   4.400 0.000101 ***
---
Signif. codes:  
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.02725 on 34 degrees of freedom
Multiple R-squared:  0.9964,	Adjusted R-squared:  0.9958 
F-statistic:  1858 on 5 and 34 DF,  p-value: < 2.2e-16
```

Dans cette étape, nous avons constaté que les p-values de toutes les variables restantes sont toutes inférieures au seuil de 0,05. Nous avons donc finalement laissé ces quatre

```
> reg3 <- lm(Flotte_Avion~.-Conso_gouv-Conso_privee,data = da
ta)
> summary(reg3)

Call:
lm(formula = Flotte_Avion ~ . - Conso_gouv - Conso_privee, da
ta = data)

Residuals:
      Min        1Q    Median        3Q       Max 
-0.051022 -0.021065  0.003515  0.019456  0.054006 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)     -6.33209    0.64002  -9.894 1.12e-11 ***
CPI              0.08006    0.01958   4.090 0.000241 ***
Exports          0.54753    0.18929   2.892 0.006532 ** 
Imports         -0.78003    0.19847  -3.930 0.000382 ***
Investissements  1.15310    0.11687   9.867 1.20e-11 ***
---
Signif. codes:  
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02722 on 35 degrees of freedom
Multiple R-squared:  0.9963,	Adjusted R-squared:  0.9958 
F-statistic:  2327 on 4 and 35 DF,  p-value: < 2.2e-16
```

variables: **CPI, Exports, Imports** et **Investissements**. Ces quatre variables sont également les quatre variables les plus significatives que nous ayons vues dans le premier modèle

3.2 Tests d'hypothèses

Afin de vérifier l'exactitude de nos résultats, nous pouvons effectuer une analyse de variance à l'aide de commande `anova()`. Il étudie la différence de différents niveaux de facteurs et l'importance de l'interaction de différents facteurs.

```
> anova(reg1,reg3)
Analysis of Variance Table

Model 1: Flotte_Avion ~ CPI + Conso_gouv + Conso_privee + Exp
orts + Imports + 
    Investissements
Model 2: Flotte_Avion ~ (CPI + Conso_gouv + Conso_privee + Ex
ports + Imports + 
    Investissements) - Conso_gouv - Conso_privee
  Res.Df      RSS Df  Sum of Sq      F Pr(>F)
1     33 0.024809                           
2     35 0.025940 -2 -0.0011311 0.7522 0.4792
```

Les informations les plus importantes sont affichées dans la dernière ligne: avec une p-value de 47%.

Et notons que, ici on réalise le test d'hypothese :

$H_0 : \beta_{Conso_privee} = \beta_{Conso_gouv} = 0 \ \ vs. H_1$: au moins un de ces coefficients est différent de 0

On prend un risque de 5%, *p_value* = 47,92% > 5% $\Longrightarrow$ On accepte H_0

Conclusion : les coefficients supprimés n'apportent pas plus d'informations dans le modèle

3.3 Analyse des résidus&Etude des points influents

L'analyse de régression est basée sur l'hypothèse des termes d'erreur, les hypothèses les plus courantes :
Nous étudierons les points où les données ont une plus grande influence sur l'inférence statistique (estimation, test, prédiction et contrôle). Ces points sont appelés points atypiques. On va éliminer les données anormales/aberrantes qui ont un fort impact sur les données.

Selon la nature de la normale standard, environ 95 % des tis tombent dans l'intervalle$[-2, 2]$. Puisque $\hat{Y}$ n'est pas lié à $\hat{\epsilon}$, la corrélation entre $\hat{y}_i$ et le résidu studentisé t_i est également très

faible. De cette façon, dans le graphique résiduel, les points $(\hat{y}_i, t_i), i = 1, \ldots, n$ devraient se situer approximativement dans la bande horizontale $|ti| \leq 2$ avec une largeur de 4, et ne montrer aucune tendance. Comme ci-dessous :

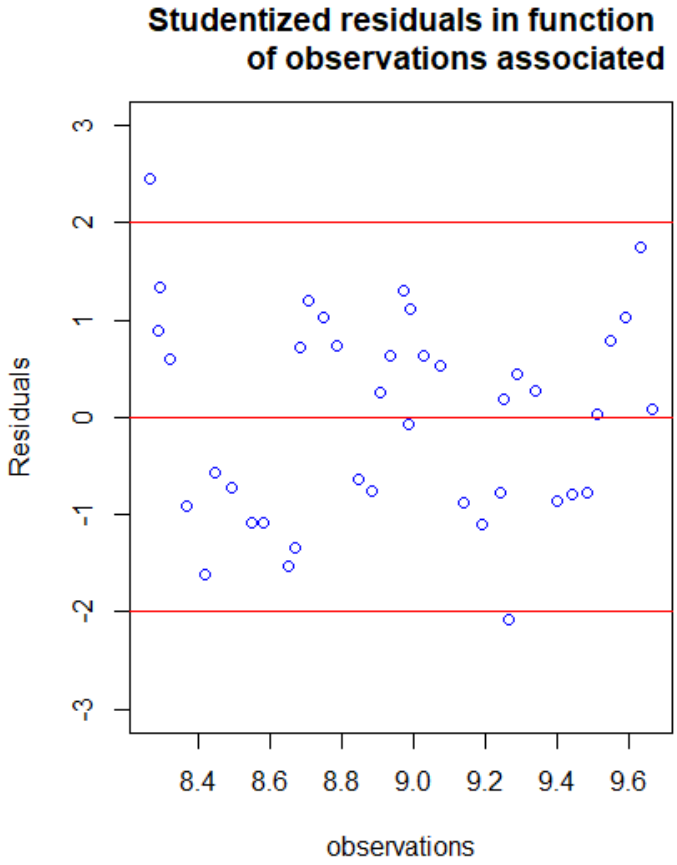

Nous pouvons trouver à travers le graphique résiduel studentisé que les individus 1 et 29 sont dans notre fourchette de jugement, et l'individu 29 est juste sur la ligne standard inférieure. Afin d'obtenir des valeurs aberrantes plus précisément, on utilise la commande `cooks.distance()` dans R pour obtenir la valeur de la statistique Cook.

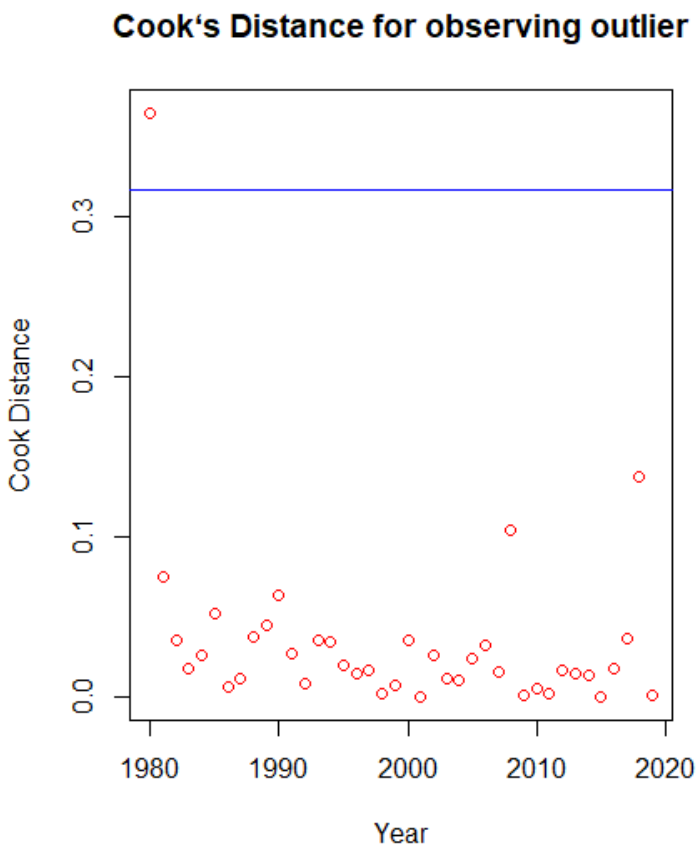

La distance de Cook résume directement les changements dans les valeurs ajustées d'autres échantillons après avoir supprimé un certain point de données, ce qui équivaut à combiner les informations du résidu et de la valeur de levier. Nous avons un tel critère : plus la distance de Cook d'un point de données est grande, plus son impact sur l'ensemble du modèle de régression est important. Grâce à cette analyse, nous avons constaté que l'individu 1 (l'année 1980) est au-dessus de la ligne standard, ce qui montre qu'il a grandement affecté les données de l'échantillon. Par conséquent, nous pouvons déjà déterminer que l'individu 1 est la donnée que nous éliminerons. Pour des individus possibles comme l'individu 29, son résidu studentisé ne s'écarte pas beaucoup. Si nous n'avons pas de raisons suffisantes pour exclure les données avec des impacts importants, nous devrions collecter plus de données ou adopter des méthodes plus robustes pour réduire l'impact des données à fort impact sur l'estimation et l'inférence, afin d'obtenir une équation de régression plus stable.

Conclusion : On va alors supprimer l'individu 1.

4 Modèle Final

Après une série d'analyses, nous pouvons enfin construire notre modèle final:

```
> modf=lm(Flotte_Avion~.-Conso_gouv-Conso_privee,data = data)
> summary(modf)

Call:
lm(formula = Flotte_Avion ~ . - Conso_gouv - Conso_privee, da
ta = data)

Residuals:
      Min        1Q    Median        3Q       Max 
-0.049868 -0.020815  0.000886  0.018982  0.046035 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)     -6.15467    0.60262 -10.213 6.78e-12 ***
CPI              0.10099    0.02018   5.004 1.70e-05 ***
Exports          0.63390    0.18040   3.514  0.00127 ** 
Imports         -0.90996    0.19290  -4.717 3.98e-05 ***
Investissements  1.18000    0.10979  10.748 1.78e-12 ***
---
Signif. codes:  
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.02545 on 34 degrees of freedom
Multiple R-squared:  0.9966,	Adjusted R-squared:  0.9962 
F-statistic:  2510 on 4 and 34 DF,  p-value: < 2.2e-16
```

L'équation établie au final est:

$$log(Flotte_Avion) = -6.15467 + 0.1\ log(CPI) + 0.63390\ log(Exports) - 0.90996\ log($$

Il s'agit d'un modèle suffisamment crédible.Nous avons remarqué que R^2_{adj} est de 0,9962, et la p-value globale est bien inférieure à 5%.

Cependant, ceux-ci ne suffisent pas comme toutes les preuves, nous devons encore tester ensuite.

4.1 Validation du modèle

Nous pouvons normalement tester notre modèle final sous trois angles

1. Si les résidus satisfaitent à l'indépendance, à la variance et à la normalité égales, et si le modèle sélectionné est approprié.
2. S'il y a des échantillons anormaux, si les résultats de l'analyse de régression reposent trop sur certains échantillons, c'est-à-dire si le modèle de régression est stable.
3. S'il y a une forte corrélation entre les variables indépendantes, c'est-à-dire s'il y a un problème de multicolinéarité (On n'y pense pas ici, car on l'a déjà traité)

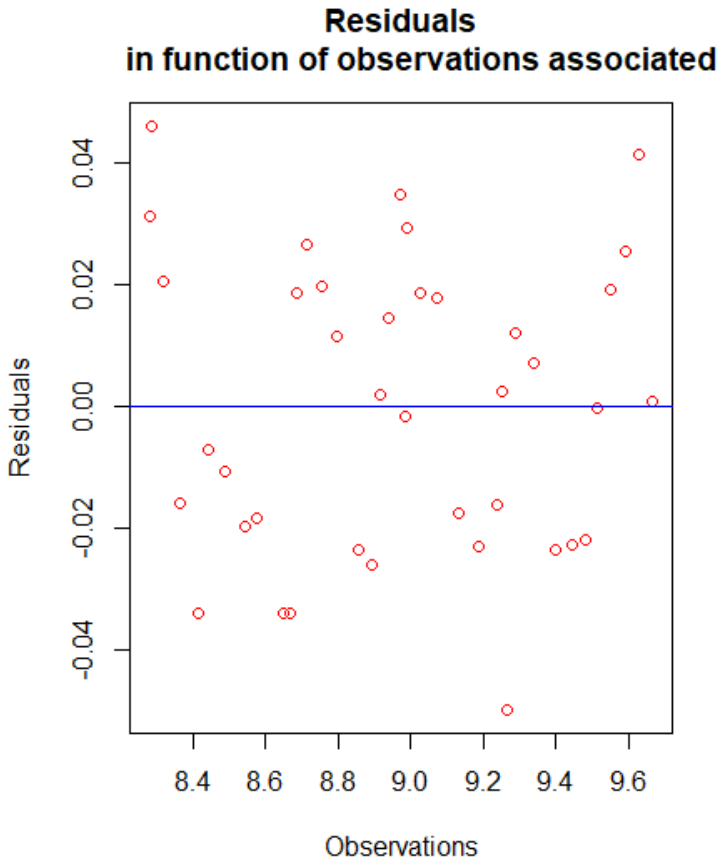

Si l'hypothèse de variance constante est satisfaite, dans la figure, les points autour de la ligne horizontale doivent être répartis de manière aléatoire.

Nous avons remarqué que les résidus dans l'image que nous avons obtenue montrent une structure 'chaotique', qui est précisément la structure la plus normale

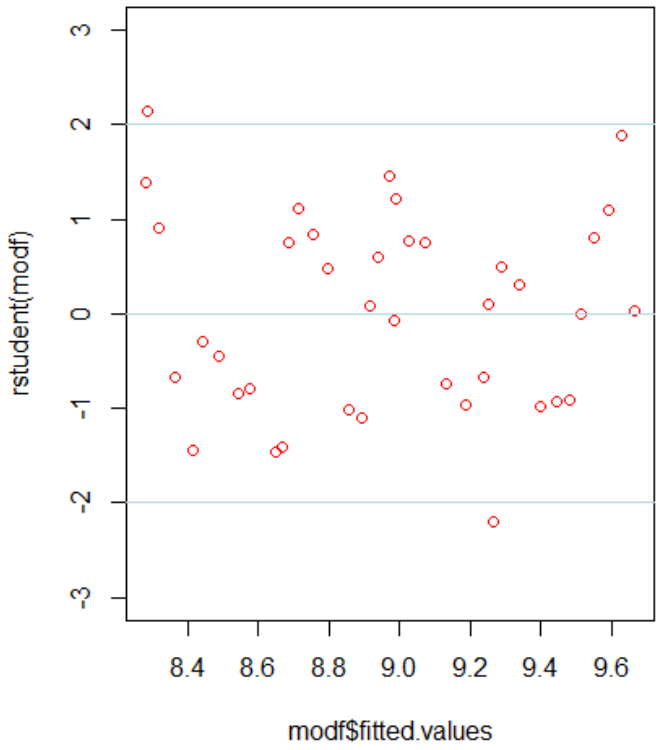

Nous avons remarqué qu'il y a encore deux points dans l'image distribués en dehors de la ligne standard (1981 et 2008), et un point (2018) est très proche de la ligne standard.

Cela nous fait commencer à prêter attention à des raisons plus réalistes.Par exemple, la Grande Récession aux États-Unis en 1981 et la crise économique mondiale en 2008 peuvent être les raisons de l'anormalité de ces deux points. Mais avant qu'il n'y ait d'autres raisons convaincantes, nous pensons que nous ne pouvons pas les supprimer.

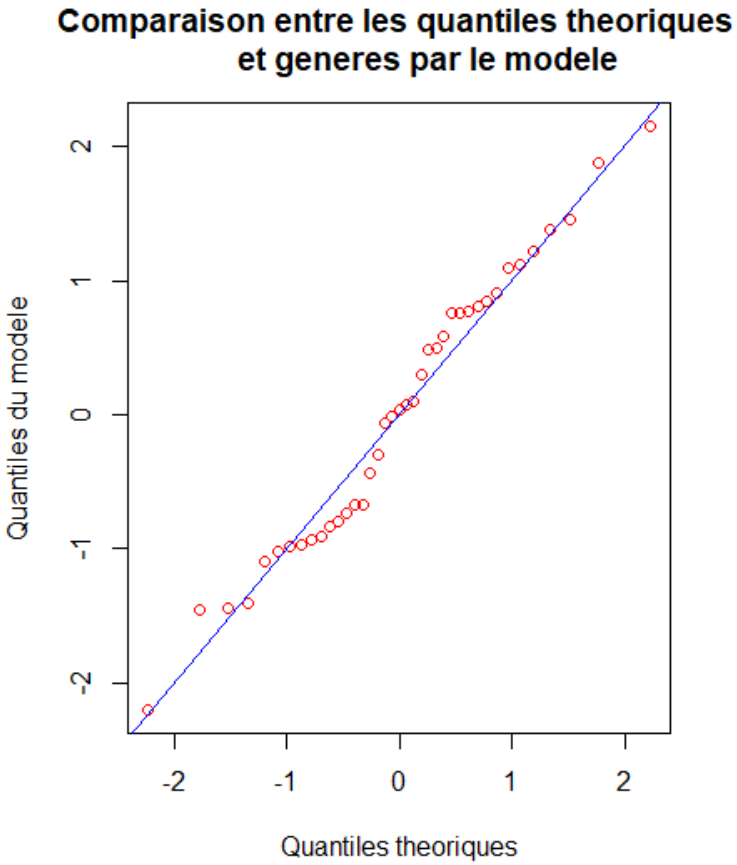

Lorsque la valeur de la variable prédictive est fixe et que la variable dépendante devient une distribution normale, le graphique résiduel doit également être une distribution normale avec une valeur moyenne de 0. Le diagramme QQ normal est un diagramme de probabilité des résidus standardisés sur la valeur correspondante de la distribution normale. Si l'hypothèse normale est satisfaite, les points du diagramme devraient tomber sur une ligne droite avec un angle de 45 degrés. Sinon, on ne prend pas la normalité.

La distribution des points de données dans ce graphique QQ-plot normal tend vers une ligne droite, indiquant que les résidus suivent une distribution normale

4.2 Intervalles de confiance

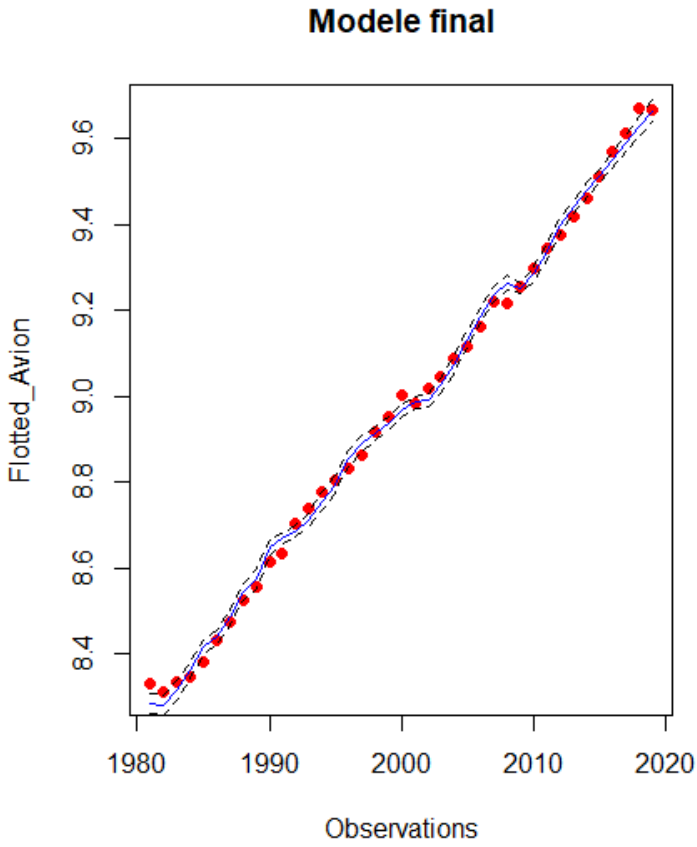

Après avoir tracé l'intervalle de confiance, nous pouvons faire des prédictions pertinentes pour notre modèle. En utilisant la fonction `predict()`, nous pouvons savoir que la probabilité que la valeur moyenne de **log (Flotte_Avion)** en 2019 tombe entre 9.639550 et 9.69142 est de 95%.

On peut également calculer les intervalles de confiance des coefficients β_i à l'aide de fonction `confint()`

rappel: $IC_{1-\alpha}(\beta_i) = [\hat{\beta}_i \pm t_{n-p}(1-\alpha/2)\hat{\sigma}_{\hat{\beta}_i}]$

```
> confint(modf)
                    2.5 %     97.5 %
(Intercept)     -7.3793480 -4.9299975
CPI              0.0599792  0.1420011
Exports          0.2672794  1.0005194
Imports         -1.3019719 -0.5179403
Investissements  0.9568762  1.4031280
```

4.3 Prediction

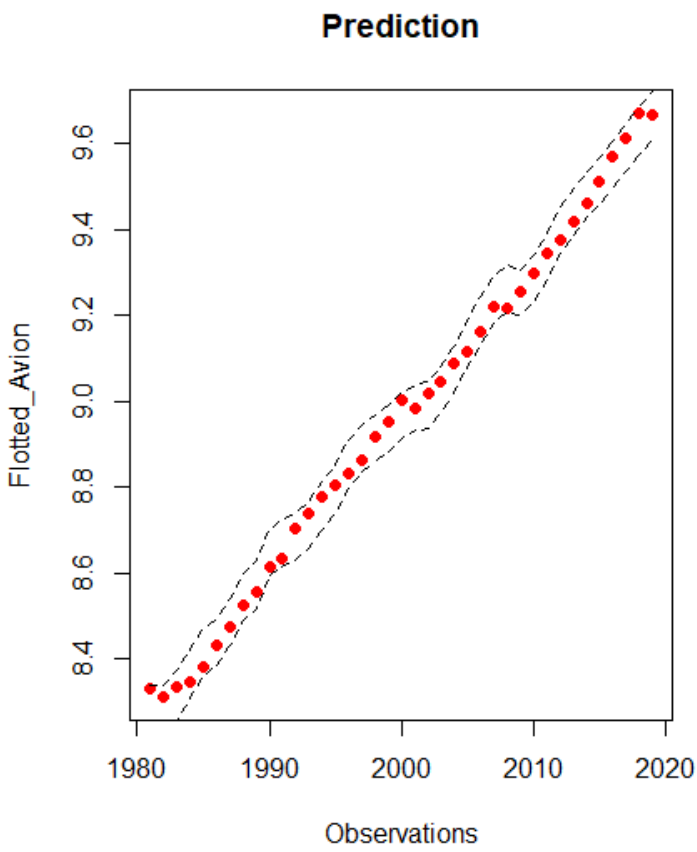

De la même manière, nous pouvons utiliser des intervalles de prédiction, un intervalle de prédiction reflète l'incertitude d'une valeur unique et un intervalle de confiance reflète l'incertitude de la moyenne prédite.

Ainsi, pour la conclusion de prédiction de **log (Flotte_Avion)** en 2019, on peut dire : 95% de **log (Flotte_Avion)** sont compris entre 9.607628 et 9.723343. Nous avons remarqué que l'intervalle de prédiction est beaucoup plus grand que l'intervalle de confiance

5 Complément

L'une des hypothèses de base de la régression multiple classique est qu'il n'y a pas de corrélation entre les résidus. S'il existe une certaine corrélation entre chaque valeur de période de l'résidu, il devient l'autocorrélation du résidu.

Nous utilisons la méthode de test DW pour tester l'autocorrélation de premier ordre. Il s'agit de la statistique DW établie à partir de la séquence résiduelle du modèle de régression.

Ici $DW = 2(1-p)$, p est le coefficient d'erreur d'ajustement du premier ordre, nous utilisons `dwtest()` dans R pour le réaliser.

```
> dwtest(modf)

        Durbin-Watson test

data:  modf
DW = 0.91124, p-value = 2.789e-06
alternative hypothesis: true autocorrelation is greater than
 0
```

Ici, la p-value est inférieure à 0,05, donc on rejette hypothèse nulle en indiquant que le résidu a une autocorrélation de premier ordre.

6 Interprétation des résultats

La fonction que nous obtenons finalement est:

$$log(Flotte_Avion) = -6.15467 + 0.1\ log(CPI) + 0.63390\ log(Exports) - 0.90996\ log($$

Nous devons noter que nous avons utilisé une fonction logarithmique pour traiter nos données, donc l'équation finale est une fonction de production Cobb-Douglas avec quatre variables indépendantes.

Si nous n'utilisons pas de logarithmes pour traiter les données au début, nous nous retrouverons avec une équation linéaire multivariée. Il est difficile de dire lequel est meilleur que l'autre, mais d'un point de vue économique en dehors des mathématiques, le modèle Cobb-Douglas peut avoir une meilleure signification pratique. (Ce modèle a été utilisé à l'origine pour décrire la relation intrants-extrants entre l'intrant travail, l'intrant capital et le PIB)

En analysant notre modèle final, nous pouvons faire les inférences suivantes:

L'impact de l'investissement sur la flotte d'avions est très important, la valeur absolue de son coefficient est la plus grande des quatre variables, c'est-à-dire que si les compagnies aériennes veulent augmenter la flotte d'avions, elles doivent d'abord envisager d'augmenter les investissements. Au contraire, s'ils veulent réduire le volume en raison de la pression du trafic, alors ils feraient mieux de commencer par investir et de réduire les investissements. C'est une conclusion qui est très intuitive et correspond à la réalité, et un apport élevé est lié à un résultat objectif.

De même, nous avons également remarqué que la valeur absolue du coefficient de valeur des importations est également très grande, et en même temps elle est négative. Cela signifie que si les compagnies aériennes veulent contrôler le flux d'avions, elles peuvent faire tout un plat sur les importations. Mon explication de cette relation est la suivante :

pour chaque entreprise, l'importation signifie que le nombre d'avions pouvant être transportés par sa propre compagnie aérienne sera réduit, réduisant ainsi le flux de manière objective. La valeur d'exportation et la valeur d'importation ne sont pas trop directement liées du point de vue économique. On peut seulement dire que l'exportation dépend de la forme la plus commode de navigation internationale, donc l'augmentation des exportations est destinée à augmenter le flux d'avions.

Quant à l'IPC, je n'ai pas pensé à une bonne explication pour expliquer cette variable. Je suppose qu'une partie de la demande de consommation des résidents inclut la demande de sorties, que ce soit pour affaires ou pour le tourisme. Par conséquent, une augmentation de la

demande entraînera inévitablement une augmentation de l'offre du côté de l'offre. Il s'agit d'une relation offre-demande très classique, bien que le coefficient de l'IPC ne soit pas important dans le modèle.

Bien sûr, dans un sens pratique, même si la relation de régression est établie et que le test statistique prouve que la corrélation est établie, il ne peut que montrer que les variables étudiées sont statistiquement liées, mais ne peut pas conclure qu'il existe une relation causale entre les variables .

Afin d'aller plus loin, en revoyant ce rapport, notre méthode de sélection des variables peut être améliorée, comme l'utilisation de l'AIC, du LASSO, etc., ou nous pouvons envisager d'ajouter d'autres facteurs d'influence possibles tels que le revenu par habitant, etc. Même dans des applications pratiques, leur relation peut être non linéaire. Dans l'ensemble, nous devons attendre plus de données et plus d'outils mathématiques pour construire un modèle plus précis.

Annexe

```
##### Projet Regression Lin´eaire #####

#importation de donnees

data = read.csv2(file="3GM_RegLin_Projets.csv",dec = ",",header = T,row.names = 1)

head(data)
knitr::kable(head(data), caption = "la flotte mondiale d’avions")
str(data)
data_initial = data #garder pour accident
data=log(data)# grande difference en prenant log ou pas
#On passe au log pour reduire la variance
summary(data)

######## Etude des correlations ########

pairs(data,labels = colnames(data))
#cor(data)
par(mfrow=c(3,3))
for (j in 1:ncol(data)){boxplot(data[,j], main=colnames(data)[j])}

####### Pretraitement #########

data=data[,-6]
#str(data)
#summary(data)
#cor(data)

######## Un premier modele ########

modele1=lm(Flotte_Avion~.,data=data)
summary(modele1)

plot(modele1$fitted.values,modele1$residuals,xlab =
       'Oservations',ylab = 'Residuals',main ='Residuals
     in function of observations associated',col='blue')
abline(h=0,col='red')
#structure rien de particulier

#plot(rstudent(modele1))
#abline(h=c(-2,2))
```

```
######## Tests d'hypotheses et reduction du nombre de param`etres ########

reg1 <- lm(Flotte_Avion~.,data=data)
summary(reg1)
#on va supprimer d'abord Conso_gouv

reg2 <- lm(Flotte_Avion~.-Conso_gouv,data = data)
summary(reg2)
#on va supprimer Conso_privee

reg3 <- lm(Flotte_Avion~.-Conso_gouv-Conso_privee,data = data)
summary(reg3)

anova(reg1,reg3)

######## Etude des points influents ########

plot(reg3$fitted.values,rstudent(reg3),xlab='observations'
     ,ylab='Residuals',col='blue',ylim=c(-3,3),main =
             'Studentized residuals in function
             of observations associated')
abline(h=0,col='red')
abline(h=2,col='red')
abline(h=-2,col='red')
which(rstudent(reg3) < -2 | rstudent(reg3) > 2)
#individu 1 et 29 sont en dehors

plot(row.names(data),cooks.distance(reg3),col='red',
     xlab='Year',
     ylab='Cook Distance',
     main = "Cook‘s Distance for observing outlier")
abline(h = qf(0.1,5, nrow(data)-5),col='blue')
which(cooks.distance(reg3)>qf(0.1,5,nrow(data)-5))
#individu 1 doit etre retirer

data=data[-1,]


######## Modele final ########

modf=lm(Flotte_Avion~.-Conso_gouv-Conso_privee,data = data)
summary(modf)

plot(modf$fitted.values, modf$residuals,col='red',
     xlab='Observations',ylab='Residuals',
     main='Residuals
     in function of observations associated')
abline(h=0,col='blue')

plot(modf$fitted.values, rstudent(modf),
     col='red', ylim = c(-3,3))
abline(h=c(-2,0,2),col='lightblue')
which(rstudent(modf) < -2 | rstudent(modf) > 2)

qqnorm(rstudent(modf),col='red',
       xlab='Quantiles theoriques',ylab='Quantiles du modele',
       main='Comparaison entre les quantiles theoriques
       et generes par le modele')
abline(b=1,a=0,col='blue')

######### Intervalles de confiance ########
IC = predict(modf, interval='confidence', level=0.95)
plot(rownames(data),data$Flotte_Avion,
     col="red", pch=19,
     xlab="Observations",
     ylab="Flotted_Avion", main="Modele final")
lines(rownames(data),modf$fitted.values, type="l", lty=1, col="blue")
lines(rownames(data),IC[,2], type="l", lty=2, col="black")
lines(rownames(data),IC[,3], type="l", lty=2, col="black")
```

```
confint(modf)

######## Intervalles de Prediction ########
prediction=predict(modf,interval = 'pred',level=0.95)
plot(rownames(data),data$Flotte_Avion,
     col="red", pch=19,
     xlab="Observations",
     ylab="Flotted_Avion", main="Prediction")
lines(rownames(data),prediction[,2], type="l", lty=2, col="black")
lines(rownames(data),prediction[,3], type="l", lty=2, col="black")


######## Complements ########
# On effectue un test de Dubin-Watson
install.packages('lmtest')
library(lmtest)
dwtest(modf)
```